CLASS 7. 파이썬 – 시각화 및 분석

수업 목차

파이썬 문법

#1. 반복문(for문)

#2. 데이터 선택

실습

#1. 프로배구 관중현황 시각화

#2. 프로농구 관중현황 시각화



미니 프로젝트

#1. 프로배구와 프로농구 관중현황 추이 비교 분석 보고서 작성



사전준비: 구름IDE 신규 컨테이너 생성

□ 주피터 노트북(Jupyter Notebook)

오픈 소스 기반 웹 애플리케이션으로 일부 코드의 실행 결과를 확인할 수 있다는 장점이 있어데이터 분석에 주로 사용된다.

파이썬 문법 #1. 반복문

반복문: 반복되어 수행하는 실행문으로, 대표적인 반복문은 for문이 있다.

기본 문법

for 반복할 변수 in 반복범위: 실행문

활용 예: 구구단

2 X 1 = 2

2 X 2 = 4

2 X 3 = 6

2 X 4 = 8

 $2 \times 5 = 10$

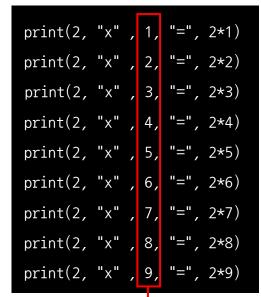
 $2 \times 6 = 12$

2 X 7 = 14

 $2 \times 8 = 16$

 $2 \times 9 = 18$

반복문 없이 출력



반복문으로 출력

for i in range(1,10):
 print(2, "x",i, "=", 2*i)

range() 함수 : 특정 구간의 숫자 범위(정수)를 만들어주는 함수

(예) range(1,3) : 1,2

range(1,4): 1,2,3

※주의. 마지막 숫자는 포함하지 않음

┗→ 변하는 부분 → 반복할 변수로 처리

파이썬 문법 #2. 데이터 선택

데이터 선택: 내가 원하는 데이터만 선택하는 것이다.

기본 문법(1) : 열 선택

df['열이름']

df[['열이름1','열이름2']]

예) 데이터프레임: df

	과일	가격
0	사과	500
1	바나나	100

1) '과일' 열만 출력하고 싶을때

df['과일']

[출력결과]

- 0 사과
- 1 바나나

2) '과일'과 '가격 '열을 출력하고 싶을때

df[['과일','가격']]

[출력결과]

	과일	가격
0	사과	500
1	바나나	100

파이썬 문법 #2. 데이터 선택

데이터 선택: 내가 원하는 데이터만 선택하는 것이다.

기본 문법(2): 열 + 행 선택

df['열이름'][행 번호]

예) 데이터프레임: df

	과일	가격
0	사과	500
1	바나나	100

1) '과일' 열의 첫 번째 데이터만 출력하고 싶을때

df['과일'][0] [출력결과] 사과

2) '가격' 열의 두 번째 데이터만 출력하고 싶을때

df['가격'][1]

[출력결과]

100

환경설정 #1. 라이브러리 설치

(터미널)

```
pip install xlrd
pip install openpyxl
```

□ xlrd, openpyxl : 파이썬 판다스에서 엑셀 파일을 다루기 위한 라이브러리

*라이브러리(Library) : 함수들의 집합

환경설정 #2. 한글 폰트 설치

(터미널)

```
sudo apt-get install -y fonts-nanum fonts-nanum-coding fonts-nanum-extra
rm -rf ~/.cache/matplotlib/*
fc-cache -fv
```

- ① 나눔폰트 설치
- ② 기존 캐시 삭제
- ③ 새로운 캐시 생성

(주피터노트북)

```
import matplotlib as mpl
import matplotlib.pyplot as plt
mpl.rcParams['axes.unicode_minus'] = False
plt.rcParams[ ' font.family ' ] = 'NanumGothic'
```

④ 나눔고딕 폰트 적용

실습 #1. 프로배구 관중현황 시각화

□ 목표 : 관중이 가장 많이 들어온 시즌 구하기(모든 대회 합계)

□ 데이터: 한국배구연맹의 2005시즌부터 2019~20시즌까지 관중현황(sample_2.xlsx)

<u>실습 FLOW</u>



step4. 그래프 그리기

→ 시즌별 관중 수 막대그래프 그리기

step5. 그래프 꾸미기

→ 옵션 사용

step 1. import

엑셀파일 → 판다스 데이터프레임으로 불러오기

- ① 업로드(Upload) > sample_2.xlsx 파일
- ② import

```
import pandas as pd
df = pd.read_excel( 'sample_2.xlsx',engine= 'openpyxl')
```

read_excel(): 엑셀 파일을 불러오는 함수

*데이터프레임(DataFrame): 행과 열로 이루어진 형태의 데이터 (예)엑셀 스프레드시트

③ 불러온 데이터 확인

df

데이터 출처: KOVO 한국배구연맹(https://www.kovo.co.kr/stats/47000_audience.asp)

	구분	컵대회	정규리그	올스타전	포스트시즌	기타대회
0	2019~20시즌	40830	393059	미개최	미진행	-
1	2018~19시즌	34104	533899	4702	41847	-
2	2017~18시즌	21617	471116	4823	41735	4602
3	2016~17시즌	32097	473853	5033	41882	4134
4	2015~16시즌	27507	466842	5172	35465	-
5	2014~15시즌	22780	461625	4075	32721	3462
6	2013~14시즌	24332	374600	5782	35906	-
7	2012~13시즌	24809	319597	4957	33964	-
8	2011~12시즌	31369	346023	7112	42718	-
9	2010~11시즌	31573	279326	2256	63967	-
10	2009~10시즌	31551	265653	6251	50316	2658
11	2008~09시즌	17716	235493	5235	37378	6222
12	2007~08시즌	20280	198183	-	36125	-
13	2006~07시즌	22495	182377	7629	37948	7750
14	2005~06시즌	-	116110	6200	37406	9400
15	2005 시즌	-	-	-	-	-

▲ df 출력 결과

step 2. 데이터 전처리

→ replace() 함수 사용

① 데이터 수정

replace(old,new) : 문자열을 변경하는 함수

→ '-'를 숫자 0으로 변경하겠다는 의미

df = df.replace('미진행',0)

② 수정된 데이터 확인

df

	구분	컵대회	정규리그	올스타전	포스트시즌	기타대회
0	2019~20시즌	40830	393059	0	0	0
1	2018~19시즌	34104	533899	4702	41847	0
2	2017~18시즌	21617	471116	4823	41735	4602
3	2016~17시즌	32097	473853	5033	41882	4134
4	2015~16시즌	27507	466842	5172	35465	0
5	2014~15시즌	22780	461625	4075	32721	3462
6	2013~14시즌	24332	374600	5782	35906	0
7	2012~13시즌	24809	319597	4957	33964	0
8	2011~12시즌	31369	346023	7112	42718	0
9	2010~11시즌	31573	279326	2256	63967	0
10	2009~10시즌	31551	265653	6251	50316	2658
11	2008~09시즌	17716	235493	5235	37378	6222
12	2007~08시즌	20280	198183	0	36125	0
13	2006~07시즌	22495	182377	7629	37948	7750
14	2005~06시즌	0	116110	6200	37406	9400
15	2005 시즌	0	0	0	0	0

▲ df 출력 결과

step 3. 원하는 데이터 구하기

→ sort_values() 함수 사용

① 모든 대회의 관중 수의 합인 '합계' 열 생성

df['합계'] = df['컵대회'] + df['정규리그'] + df['올스타전'] + df['포스트시즌'] + df['기타대회']

② 관중이 가장 많이 들어온 시즌 (시즌 모든 대회 합계)

df = df.sort_values(by=['합계'],ascending=False)

step 3. 원하는 데이터 구하기

→ sort_values() 함수 사용

③ 시즌 오름차순 정렬

df = df.sort_values(by=['구분'],ascending=True) df = df.reset_index(drop=True)

	구분	컵대회	정규리그	올스타전	포스트시즌	기타대회	합계
0	2019~20시즌	40830	393059	0	0	0	433889
1	2018~19시즌	34104	533899	4702	41847	0	614552
2	2017~18시즌	21617	471116	4823	41735	4602	543893
3	2016~17시즌	32097	473853	5033	41882	4134	556999
4	2015~16시즌	27507	466842	5172	35465	0	534986
5	2014~15시즌	22780	461625	4075	32721	3462	524663
6	2013~14시즌	24332	374600	5782	35906	0	440620
7	2012~13시즌	24809	319597	4957	33964	0	383327
8	2011~12시즌	31369	346023	7112	42718	0	427222
9	2010~11시즌	31573	279326	2256	63967	0	377122
10	2009~10시즌	31551	265653	6251	50316	2658	356429
11	2008~09시즌	17716	235493	5235	37378	6222	302044
12	2007~08시즌	20280	198183	0	36125	0	254588
13	2006~07시즌	22495	182377	7629	37948	7750	258199
14	2005~06시즌	0	116110	6200	37406	9400	169116
15	2005 시즌	0	0	0	0	0	0



	구분	컵대회	정규리그	올스타전	포스트시즌	기타대회	합계
15	2005 시즌	0	0	0	0	0	0
14	2005~06시즌	0	116110	6200	37406	9400	169116
13	2006~07시즌	22495	182377	7629	37948	7750	258199
12	2007~08시즌	20280	198183	0	36125	0	254588
11	2008~09시즌	17716	235493	5235	37378	6222	302044
10	2009~10시즌	31551	265653	6251	50316	2658	356429
9	2010~11시즌	31573	279326	2256	63967	0	377122
8	2011~12시즌	31369	346023	7112	42718	0	427222
7	2012~13시즌	24809	319597	4957	33964	0	383327
6	2013~14시즌	24332	374600	5782	35906	0	440620
5	2014~15시즌	22780	461625	4075	32721	3462	524663
4	2015~16시즌	27507	466842	5172	35465	0	534986
3	2016~17시즌	32097	473853	5033	41882	4134	556999
2	2017~18시즌	21617	471116	4823	41735	4602	543893
1	2018~19시즌	34104	533899	4702	41847	0	614552
0	2019~20시즌	40830	393059	0	0	0	433889



구분 컵대회 정규리그 올스타전 포스트시즌 기타대회 9400 169116 37406 2006~07시즌 22495 182377 7629 37948 7750 258199 36125 0 254588 5235 37378 6222 302044 2008~09시즌 17716 235493 50316 2658 356429 5 2009~10시즌 31551 265653 6251 2010~11시즌 31573 279326 2256 63967 0 377122 7112 42718 0 427222 0 383327 4957 2013~14시즌 24332 374600 5782 35906 0 440620 2014~15시즌 22780 461625 4075 32721 3462 524663 5172 35465 0 534986 2016~17시즌 32097 473853 5033 41882 4134 556999 4823 41735 4602 543893 0 614552 14 2018~19시즌 34104 533899 4702 41847 0 433889

최근 시즌부터 내림차순

과거 시즌부터 오름차순

인덱스 재지정

step 3. 원하는 데이터 구하기

→ mean() 함수 사용

④ 시즌 관중 평균

df['합계'].mean()

(응용) 시즌 관중 최대값

df['합계'].max()

(응용) 시즌 관중 최소값

df['합계'].min()

step 4. 그래프 그리기

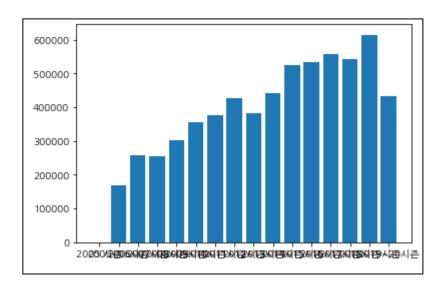
→ 시즌별 관중 수 막대그래프(bar chart) 그리기

① 막대그래프 그리기

```
import matplotlib.pyplot as plt
plt.bar(df['구분'],df['합계'])
plt.show()
```

plt.bar(x, y) : 막대그래프 그리는 함수

plt.show(): 그래프 출력 함수



step 5. 그래프 꾸미기

→ 옵션 사용

```
plt.figure(figsize=(20,10)) #그래프 사이즈(가로, 세로) (단위:인치)
plt.bar(df['구분'],df['합계'], color="green") #막대 색상 변경(색상=초록색)

plt.title('시즌별 관중 현황',fontsize=20) #그래프 제목 입력(글자크기=20)
plt.xticks(df['구분'],rotation=45) #x축 입력(회전=45도)
plt.xlabel('시즌',fontsize=15) #x축 이름(글자크기=15)

plt.ylabel('관중 수',fontsize=15) #y축 이름(글자크기=15)

for i in range(len(df['구분'])):
   plt.text(i-0.4,df['합계'][i]+5000, format(df['합계'][i],","),fontsize=13)

plt.show()
```

데이터 레이블 표시

plt.text(x좌표, y좌표, 레이블) 함수: 데이터 레이블 출력 함수

(기본) plt.text(i, df['합계'][i], df['합계'][i])

→ x좌표, y좌표 조금씩 이동하며 위치 조절

(옵션) 출력형식 지정: format(데이터, "형식")함수 사용

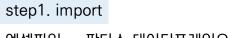
→ ",": 천단위 구분자 지정 (예) 123,567

실습 #2. 프로농구 관중현황 시각화

□ 목표 : 관중이 가장 많이 들어온 시즌 구하기

□ 데이터: 한국프로농구의 2005시즌부터 2019~20시즌까지 관중현황(sample_3.xlsx)

<u>실습 FLOW</u>



엑셀파일 → 판다스 데이터프레임으로 불러오기

step2. 원하는 데이터 구하기

→ sort_values() 함수 사용

→ mean() 함수 사용

step3. 그래프 그리기

→ 시즌별 관중 수 막대그래프 그리기

step4. 그래프 꾸미기

→ 옵션 사용

```
step 1. import
```

엑셀파일 → 판다스 데이터프레임으로 불러오기

- ① 업로드(Upload) > sample_3.xlsx 파일
- ② import

```
import pandas as pd
df = pd.read_excel( 'sample_3.xlsx',engine= 'openpyxl')
```

read_excel(): 엑셀 파일을 불러오는 함수

*데이터프레임(DataFrame): 행과 열로 이루어진 형태의 데이터 (예)엑셀 스프레드시트

③ 불러온 데이터 확인

df

데이터 출처: 한국프로농구(https://www.kbl.or.kr/story/record)

	구분	합계
0	2019~20시즌	653355
1	2018~19시즌	873782
2	2017~18시즌	848395
3	2016~17시즌	927844
4	2015~16시즌	1030846
5	2014~15시즌	1171658
6	2013~14시즌	1303988
7	2012~13시즌	1211641
8	2011~12시즌	1333857
9	2010~11시즌	1154948
10	2009~10시즌	1136980
11	2008~09시즌	1228855
12	2007~08시즌	1155399
13	2006~07시즌	1160113
14	2005~06시즌	1104503

▲ df 출력 결과

step 2. 원하는 데이터 구하기

→ sort_values() 함수 사용

① 관중이 가장 많이 들어온 시즌

df.sort_values(by=['합계'], ascending=False)

sort_values(by=[정렬 컬럼명], ascending = False): 데이터 정렬 함수

- → '합계'열을 기준으로 내림차순 정렬하겠다는 의미
- *오름차순 정렬을 하고싶으면 ascending=True

	구분	합계
8	2011~12시즌	1333857
6	2013~14시즌	1303988
11	2008~09시즌	1228855
7	2012~13시즌	1211641
5	2014~15시즌	1171658
13	2006~07시즌	1160113
12	2007~08시즌	1155399
9	2010~11시즌	1154948
10	2009~10시즌	1136980
14	2005~06시즌	1104503
4	2015~16시즌	1030846
3	2016~17시즌	927844
1	2018~19시즌	873782
2	2017~18시즌	848395
0	2019~20시즌	653355

▲ '합계' 기준 내림차순 정렬

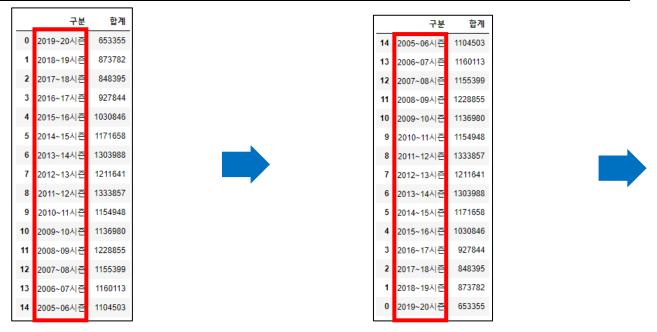
step 2. 원하는 데이터 구하기

→ sort_values() 함수 사용

최근 시즌부터 내림차순

② 시즌 오름차순 정렬

df = df.sort_values(by=['구분'],ascending=True)
df = df.reset_index(drop=True)



과거 시즌부터 오름차순



인덱스 재지정

step 3. 그래프 그리기

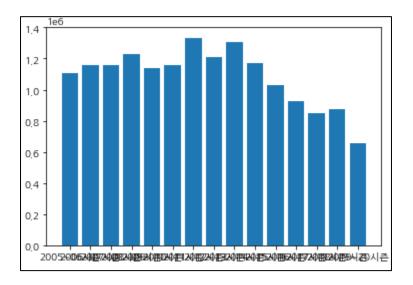
→ 시즌별 관중 수 막대그래프(bar chart) 그리기

① 막대그래프 그리기

```
import matplotlib.pyplot as plt
plt.bar(df['구분'],df['합계'])
plt.show()
```

plt.bar(x, y) : 막대그래프 그리는 함수

plt.show(): 그래프 출력 함수



step 3. 그래프 꾸미기

→ 옵션 사용

① 옵션 사용

```
plt.figure(figsize=(20,10))
plt.bar(df['구분'],df['합계'], color="orange") #막대 색상 변경(색상=주황색)
plt.title('시즌별 관중 현황',fontsize=20) #그래프 제목 입력(글자크기=20)
plt.xticks(df['구분'],rotation=45) #x축 입력(회전=45도)
plt.xlabel('시즌',fontsize=15) #x축 이름(글자크기=15)
plt.ylabel('관중 수',fontsize=15) #y축 이름(글자크기=15)

for i in range(len(df)):
   plt.text(i-0.4,df['합계'][i]+10000, format(df['합계'][i],","),fontsize=13)
plt.show()
```

데이터 레이블 표시

plt.text(x좌표, y좌표, 레이블) 함수: 데이터 레이블 출력 함수

(기본) plt.text(i, df['합계'][i], df['합계'][i])

→ x좌표, y좌표 조금씩 이동하며 위치 조절

(옵션) 출력형식 지정: format(데이터, "형식")함수 사용

→ ",": 천단위 구분자 지정 (예) 123,567

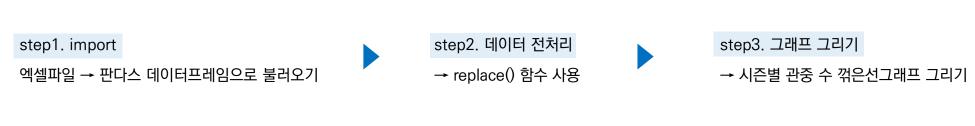
미니 프로젝트 #1. 프로배구와 프로농구 관중현황 추이 비교 분석 보고서 작성

□ 목표 : 관중현황 추이 비교 분석 보고서 작성

□ 데이터: 한국프로배구의 2005시즌부터 2019~20시즌까지 관중현황,

한국프로농구의 2005시즌부터 2019~20시즌까지 관중현황

<u>실습 FLOW</u>



 step4. 그래프 꾸미기
 step5. 보고서 작성

 → 옵션 사용
 → 프로배구와 프로농구 관중현황 추이 비교 분석 보고서

step 1. import

- → 프로배구 데이터 : df1 (sample_1.xlsx)
- → 프로농구 데이터 : df2 (sample_2.xlsx)

```
import pandas as pd
import matplotlib.pyplot as plt

df1 = pd.read_excel( 'sample_2.xslx ',engine= 'openpyxl ')

df2 = pd.read_excel( 'sample_3.xslx ',engine= 'openpyxl ')
```

step 2. 데이터 전처리

- → 프로배구 데이터 : df1 (sample_1.xlsx)
- → 프로농구 데이터 : df2 (sample_2.xlsx)

```
df1 = df1.replace('-',0)
df1 = df1.replace('미개최',0)
df1 = df1.replace('미진행',0)
df1 = df1.replace('미진행',0)
df1['합계'] = df1['컵대회'] + df1['정규리그'] + df1['올스타전'] + df1['포스트시즌'] + df1['기타대회']

df1 = df1.sort_values(by=['구분'],ascending=True)
df1 = df1.reset_index(drop=True)
df2 = df2.sort_values(by=['구분'],ascending=True)
df2 = df2.reset_index(drop=True)
```

step 3~4. 그래프 그리기 + 꾸미기

- → 시즌별 관중 수 꺾은선그래프(line chart) 그리기
- → 옵션 사용

```
plt.figure(figsize=(20,10))
plt.plot(df1['구분'],df1['합계'],color="green", linewidth=5)
plt.plot(df2['구분'],df2['합계'],color="orange", linewidth=5)
plt.title('프로배구, 프로농구 관중 현황 추이 비교', fontsize=20)
plt.xlabel('시즌', fontsize=15)
plt.ylabel('관중 수(명)', fontsize=15)
plt.xticks(df['구분'],rotation=45)
plt.legend(['프로배구','프로농구'], fontsize=20)
plt.show()
```

[보고서 작성 예]

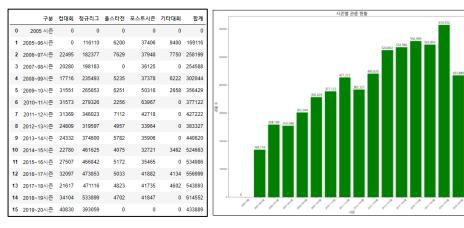
□ 개요

- 1) 데이터: 한국프로배구 2005시즌부터 2019~20시즌까지 관중현황한국프로농구 2005시즌부터 2019~20시즌까지 관중현황
- 2) 데이터 출처: KOVO 한국배구연맹, 한국프로농구

□ 분석 결과

1) 프로배구

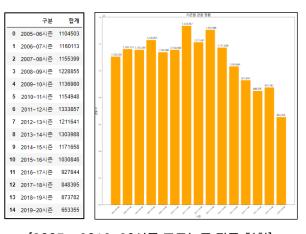
- 2018~19시즌에 총 614,552명으로 가장 많은 관중을 동원했다.
- 2005시즌부터 점자 증가하는 추세를 보인다.



[2005 ~ 2019-20시즌 프로배구 관중 현황]

2) 프로농구

- 2011~12시즌에 가장 많은 1,333,857명의 관중을 동원했다.
- 2013~14시즌을 기점으로 점차 관중 수가 줄어드는 추세를 보인다.

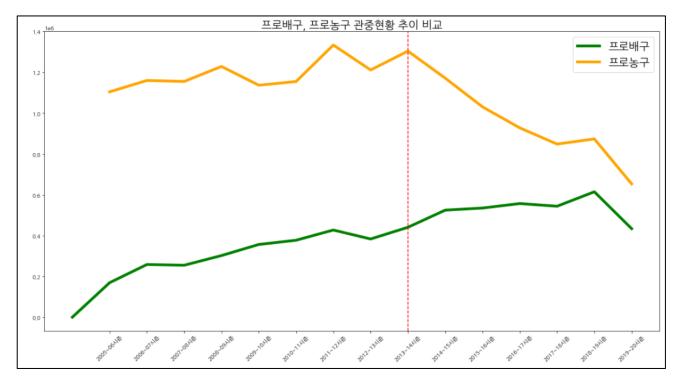


[2005 ~ 2019-20시즌 프로농구 관중 현황]

[보고서 작성 예]

□ 비교 분석 결과

- 프로배구의 시즌 평균 관중은 약 386,103 명이고, 프로농구의 시즌 평균 관중은 약 1,086,410 명이다.
- 2013~14시즌을 기점으로 프로농구의 관중수는 줄어드는 추세를 보이는 반면 프로배구는 2005~06시즌부터 꾸준하게 증가하는 추세를 보여 그 차이는 줄어들고 있다.



[2005 ~ 2019-20시즌 프로배구, 프로농구 관중 현황 추이 비교]

※과제. 프로배구와 프로농구 관중현황 추이 비교 분석 보고서 작성

- 가. 제출: wowsjh02@gmail.com
- 나. 필수 포함 내용
 - 그래프에 대한 분석 결과(예. 증가하는 추이를 보인다.) 작성
 - 프로배구의 관중이 증가 또는 감소하는 원인 1가지 찾기
 - 프로농구의 관중이 증가 또는 감소하는 원인 1가지 찾기

*주의. 분석 리포트 작성 시 데이터 출처 반드시 명시할 것